AULA CONSULTA

Consultar documentos educativos con búsqueda semántica en la nube

ACA 1 · Computación en la Nube · Especialización en Inteligencia Artificial · CUN · Grupo 8

ANTERNOL DE LOS REYES BEDOYA NARANJO · MIGUEL JOSÉ GUTIÉRREZ CASTRO · CARLOS IVAN NUÑEZ FIERRO
JUAN RICARDO SANDOVAL ALVAREZ · NATALIA SEPULVEDA RAMIREZ

1. Qué quisimos resolver

Cuando necesitamos conocer un derecho o un apoyo de la universidad, la información puede estar en distintos documentos. La idea fue hacer una pregunta en español y encontrar los apartes que nos ayuden a resolverla, con su fuente y página.

2. Con qué trabajamos

Usamos tres documentos de la CUN: reglamento estudiantil, reglamento de bienestar y política de bienestar. En total son 88 páginas. También consultamos en SQLite la base Student Performance de UCI: 395 estudiantes y 33 columnas.

Cómo relacionamos las fuentes

Las relacionamos por temas como estudio, familia y acompañamiento. Hay una diferencia que debemos tener clara: la base corresponde a estudiantes de Portugal. No estamos diciendo que esos estudiantes sean de la CUN ni que una fuente explique la otra.

3. Cómo hicimos la consulta

Primero sacamos el texto de los PDF y lo dividimos por página en fragmentos. Después, el modelo E5 convirtió cada fragmento en un vector, es decir, una representación numérica de su contenido. Los guardamos en Qdrant Cloud, en AWS São Paulo.

Las decisiones que tomamos

Los fragmentos tienen hasta 220 palabras; repetimos 40 entre ventanas para conservar contexto. Usamos multilingual-e5-small, de 384 dimensiones, con los prefijos passage: y query: y vectores normalizados. El máximo observado fue de 366 tokens.

La pregunta pasa por el mismo modelo. Qdrant compara por similitud coseno y devuelve los tres fragmentos más cercanos, con documento y página.

Qué hace la nube

El portátil calcula los vectores; la nube los almacena y realiza la búsqueda. Recuperamos textos de los documentos, sin generar una respuesta nueva con un LLM. La clave queda en .env y se excluye de la entrega.

4. Qué nos dio la prueba

Cargamos 183 fragmentos y confirmamos 183 puntos remotos. Hicimos cinco preguntas y recibimos tres resultados por cada una. La consulta remota tardó entre 0,60 y 0,64 segundos, sin contar el cálculo del vector. Al recalcular el coseno, la diferencia fue menor de 0,000001.

Qué encontramos al revisar

Para derechos, el primer resultado sí fue útil: reglamento estudiantil, página 26, similitud 0,8692. Para familia, encontramos contenido en la política de bienestar, página 21 (0,8716). En apoyos económicos, el segundo resultado respondió mejor que el primero. Las páginas son las posiciones dentro del PDF.

5. Qué nos dejó este ejercicio

También preguntamos por una pizza. El sistema devolvió textos que no respondían, aunque el puntaje llegó a 0,7835. No basta con encontrar un texto parecido: hay que revisar si responde lo que preguntamos. El puntaje no es una probabilidad de acierto. Falta ampliar y validar la evaluación de pertinencia.

Referencias y acceso a las fuentes

Cortez, P. (2008). Student Performance [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5TG7T

Corporación Unificada Nacional de Educación Superior. (s. f.). Reglamento estudiantil; Reglamento de bienestar; Política de bienestar. Portal de normatividad.

intfloat. (s. f.). multilingual-e5-small [Modelo]. Hugging Face. https://huggingface.co/intfloat/multilingual-e5-small

VER VIDEO DE SUSTENTACIÓN - GRUPO 8 · VER CÓDIGO Y RESULTADOS EN GITHUB